练习做得更好，撤去AI后呢?

研究问题：AI辅助的任务成功，能否转成独立解题能力?

Bastani等（2025） | 高中数学现场实验

工具可用时：能否完成练习?

工具撤去后：能否独立完成相似题?

生产力证据之后，还需看独立掌握

作者把评价重心从“工具在场时”推进到“工具撤去后”。

证据关注点	评价时点	教育问题
已有研究（作者回顾）	工具可用时	任务质量与效率
本研究增加的比较	工具撤去后	短期独立解题

外部生产力研究仅按本文引言回顾，不作独立全文比较。

三种练习条件，差别在怎样提供帮助

GPT Tutor同时改变答案提供方式与题目专用指导。

练习条件	可用资源	帮助方式
无AI对照	课本、笔记	常规自主练习
GPT Base	GPT-4聊天界面	帮助解题，可给答案
GPT Tutor	GPT-4 + 教师题目材料	给提示；避免直接给答案

Tutor还获得正确解答、常见错误与反馈建议；各成分未单独随机操纵。

Bastani等，2025 · Experimental Design；Fig.1

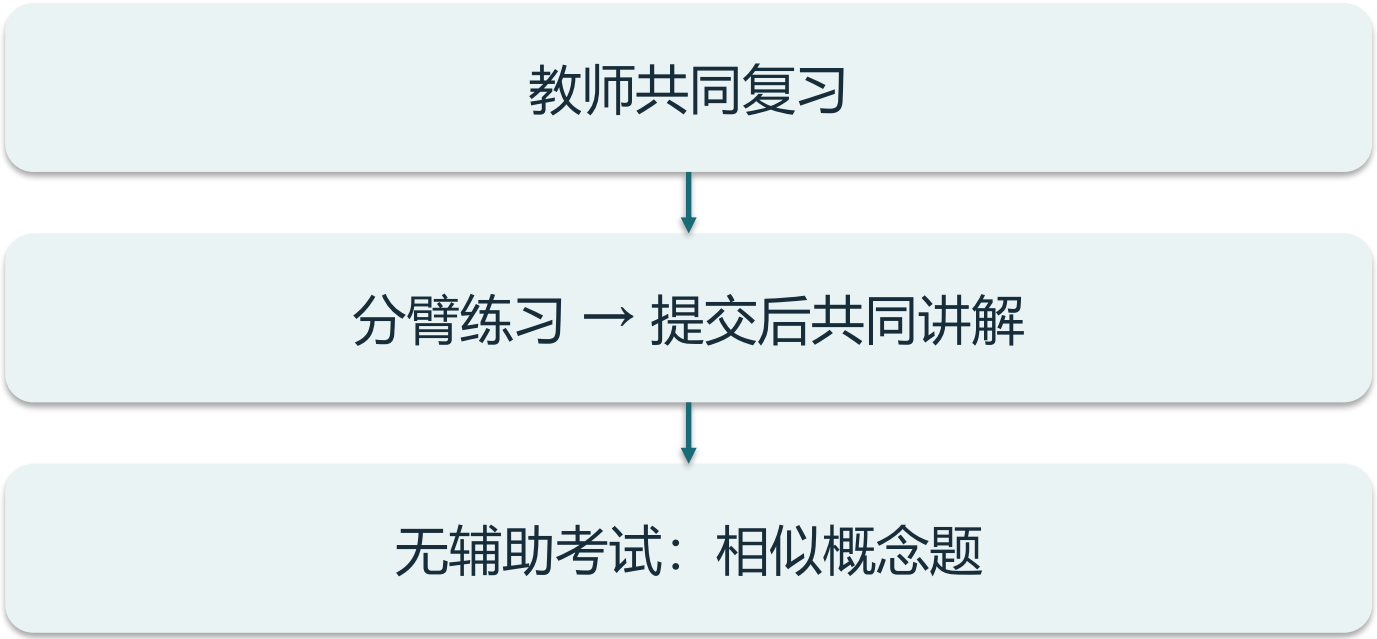
同一课次，把辅助表现与独立表现接起来

预注册主要结局：练习之后的无辅助考试成绩。

一所土耳其高中；9–11年级，近千名学生。

四次90分钟复习课；干预按课堂分配。

普通班随机组成；主分析排除荣誉班。



同课次连续完成；评价短期独立表现。

Bastani等，2025 · Experimental Design；Main Results；脚注#

练习成绩：两种工具都带来提高

工具在场时，GPT Tutor的成绩增幅点估计更大。

相对无AI对照	调整后差值（SE）	原文相对提高
GPT Base	+0.137（0.031）	约48%
GPT Tutor	+0.361（0.032）	约127%

成绩0–1；对照均值0.284；两项p<.01；SE为HC1按班级聚类标准误。

Bastani等，2025 · Table1，列1

考试成绩：Base出现损失，Tutor未检出收益

Base考试下降；Tutor估计接近零，未检出显著差异。

相对无AI对照	调整后差值（SE）	原文推断
GPT Base	−0.054（0.022）	p<.05；约下降17%
GPT Tutor	−0.004（0.013）	未检出显著差异

成绩0–1；对照均值0.321；SE按班级聚类；未显著不代表等效。

Bastani等，2025 · Table1，列2；Main Results

日志支持“答案依赖”，但机制未被单独识别

原作者的“拐杖”解释有过程依据，错误传播仍未排除。

观察到什么	怎样理解
Base常索要答案；Tutor较多求助和尝试	支持答案依赖解释
逻辑错误率与考试损失的交互未显著	不能排除错误传播
Tutor同时改变提示与解答可靠性	尚不能拆分各成分作用

互动日志与错误率分析是机制线索；不是单独随机化的机制检验。

Bastani等，2025 · Potential Mechanism；Table2；Student Engagement

部署判断：保护独立尝试，检查撤去后的表现

汇报者借鉴：学校应把独立学习作为AI部署的验收条件。

练习高分与积极自评，都不足以替代独立测验。

在相似数学任务中，应优先设计提示与可靠指导。

范围：单校数学、2023年工具、短期考试。

后续：检验延迟保持，并拆分教学保护成分。

Bastani等，2025 · Student Perception；Discussion

一句话：AI的教育价值，要看撤去后还会什么

Bastani等的课堂实验将“独立学习能否保留”带入AI评价。

普通聊天式AI提高练习表现却降低短期独立考试成绩；教学保护版损失点估计更小，未显示考试收益。

Bastani, Bastani, Sungu, Ge, Kabakcı & Mariman（2025） | PNAS 122(26), e2422633122

Generative AI without guardrails can harm learning: Evidence from high school mathematics

DOI：10.1073/pnas.2422633122

更正 DOI：10.1073/pnas.2518204122（仅作者单位）

Bastani等，2025 · Abstract；Table1；Discussion; PNAS更正，2025 · 更正全文